



Module #3 - Exercice - Enoncé

Analyse d'écoute musicale avec dbt Cloud et BigQuery

En tant qu'Analytics Engineer dans le streaming musical, votre objectif est de transformer des données brutes en un classement des 20 artistes les plus écoutés des 2 dernières années. Pour cela, vous allez charger les données brutes dans BigQuery, créer des modèles dbt pour les nettoyer, les enrichir, puis produire un modèle final d'analyse.

1. Chargement des données dans BigQuery

- Téléchargez les datasets `songs.csv` et `listening_data.csv`.
- importez-les dans BigQuery dans le dataset `spotify` sous les noms `songs` et `listening_data`.

2. Mise à jour du fichier sources.yml

- Dans votre projet dbt, mettez à jour le fichier `sources.yml` pour y faire apparaître les tables `songs` et `listening_data` précédemment uploadées sur BigQuery.

3. Création des modèles de nettoyage - staging 🏆

- **Modèle** `stg_spotify_songs`
 - Formatez les noms des artistes et titres en majuscules.
 - Remplacez les valeurs nulles de genre par "Unknown".
- **Modèle** `stg_spotify_listening_data`
 - Assurez-vous que `listen_date` est au format date.
 - Remplacez les valeurs nulles dans `minutes_listened` par 0.

4. Création d'un modèle intermédiaire - intermediate 🏆

- **Modèle** `int_spotify_song_listening`
 - Join les modèles `stg_spotify_songs` et `stg_spotify_listening_data`.
 - Filtrez sur les 2 dernières années.

5. Création d'un modèle final - mart 🏆

- **Modèle** `mrt_spotify_top_artists`
 - À partir du modèle `int_spotify_song_listening`, agrégez les minutes écoutées par artiste.
 - Classez les artistes par `minutes_listened` en ordre descendant.
 - Limitez le résultat aux 20 artistes les plus écoutés.

- Matérialisez l'objet en table au niveau du modèle.

Résultats Attendus

À la fin de cet exercice, vous aurez :

- Deux modèles niveau staging 🧪 (`stg_spotify_songs` , `stg_spotify_listening_data`) qui nettoient les données brutes.
- Un modèle niveau intermediate 🧪 (`int_spotify_song_listening`) qui enrichit et prépare les données pour analyse.
- Un modèle niveau mart 🏆 (`mrt_top_artists`) qui affiche les artistes les plus écoutés par ordre descending.