

TD 9 – Tests et documentation avec DBT

Dans les exercices de ce TD, vous allez reprendre les modèles créés lors des TD précédents. L'idée est de tester les données et documenter les modèles comme si elles appartenaient à une véritable entreprise pour laquelle vous travaillez en tant que Data Engineer.

Exercice 1 : Rédaction de la documentation

Créez un fichier de configuration `schema.yml` dans les sous-dossiers `/google_analytics` et `/sales_database` du répertoire `staging`, ainsi que dans tous les sous-dossiers des répertoires `intermediate` et `mart`.

Dans ce fichier, listez et documentez les modèles créés précédemment.

- Pour les modèles de `staging` : décrivez directement dans le fichier les clés primaires et étrangères + les éventuelles colonnes qui sont le résultat d'un calcul spécifique.
- Pour les modèles de `intermediate` et `mart` : rédigez une description dans un fichier `.md` en suivant le template fourni. Faire un fichier de configuration `yml` par modèle, le fichier de configuration devra porter le même nom que le modèle et être dans le même dossier, tout comme le fichier `.md` (suivre cette documentation pour le fichier `.md` : <https://docs.getdbt.com/docs/build/documentation>).

Faire toutes les descriptions de cet exercice en anglais.

Exercice 2 : Rédaction des tests

Partie 1 : test génériques

1) Implémentation des tests génériques :

Sur les clés primaires : Implémentez des tests génériques sur les clés primaires de toutes les tables présentes dans le répertoire `staging`. Chaque clé primaire doit être unique et non nulle.

2) Tests sur les valeurs des colonnes :

Implémentez également des tests génériques sur les colonnes dont les valeurs doivent être comprises dans une certaine liste prédéfinie.

3) Test sur les clés étrangères :

Implémenter des tests génériques de type 'relationships' sur les clés étrangères des tables (<https://docs.getdbt.com/docs/build/data-tests>) pour le dossier `staging`. Qu'est-ce que ce test relationship vérifie ?

Ajoutez des noms à vos tests génériques lorsque cela vous semble nécessaire. Pour cela suivre cette documentation : <https://docs.getdbt.com/reference/resource-properties/data-tests?version=2.0&name=Fusion#custom-data-test-name>

Partie 2 : Test singular

1) Tests spécifiques sur `stg_sales_database.order_item`

Assurez-vous qu'aucune commande sur ce modèle n'ait un montant total négatif.

2) Ajout d'un test supplémentaire :

Proposer et implémenter un autre test singular pertinent pour améliorer la robustesse de vos modèles.